#### 计算机组织结构

# 3 数据的机器级表示

刘博涵 2023年9月19日



# 教材对应章节



第2章 数据的机器级表示



第10章 计算机算术



### 信息的二进制编码

#### ・ 什么是信息?

Information is a message that is previously uncertain to receivers

#### ・ 怎么表示信息?

Codebook (Dictionary)

#### ・ 怎么度量信息?

朴素的做法: 度量码长(前提是什么?)

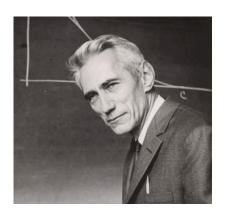
#### • 三个公理

- · Monotonicity in event probability
- Additivity
- Continuity

以2为底: bit

• 自信息量:  $I(x_i) = -log_2$   $(x_i)$ 

• 一个系统的信息熵:  $H(X) = E[I(X)] = -\sum_i p(x_i) \log_2 p(x_i)$ 



#### **Claude Elwood Shannon**

#### The Bell System Technical Journal

Vol. XXVII

July, 1948

No. 3

A Mathematical Theory of Communication

By C. E. SHANNON

Introduction

THE recent development of various methods of modulation such as PCM and PPM which exchange bandwidth for signal-to-noise ratio has intensified the interest in a general theory of communication. A basis for such a theory is contained in the important papers of Nyquist' and Hartley on this subject. In the present paper we will extend the theory to include a number of new factors, in particular the effect of noise in the channel, and the savings possible due to the statistical structure of the original message and due to the nature of the final destination of the information.



### 信息的二进制编码

・ 假设有A, B, C, D四个事件, 发生的概率分别为1/2, 1/4, 1/8, 1/8

事件	编码一	编码二	编码三
Α	00	0	0
В	01	10	1
С	10	110	01
D	11	111	10
平均码长	2bit	7/4bit	错误编码

• 
$$H(X) = E[I(X)] = -\sum_{i} p(x_{i}) log_{2} p(x_{i})$$

$$E[I(X)] = -\frac{1}{2} log_{2} \frac{1}{2} - \frac{1}{4} log_{2} \frac{1}{4} - \frac{1}{8} log_{2} \frac{1}{8} - \frac{1}{8} log_{2} \frac{1}{8}$$

$$E[I(X)] = \frac{7}{4}$$



### 信息的二进制编码

- 在冯·诺依曼结构中,所有信息(代码和数据)都采用二进制编码
  - 编码:用少量简单的基本符号对复杂 多样的信息进行一定规律的组合
  - 采用二进制的原因
    - 制造两个稳定态的物理器件容易
    - 二进制编码、计数运算规则简单
    - 对应逻辑命题中的"真"和"假"
    - 便于使用逻辑电路实现算术运算
  - 真值和机器数
    - K位的二进制编码至多表示2<sup>k</sup>个不同的值

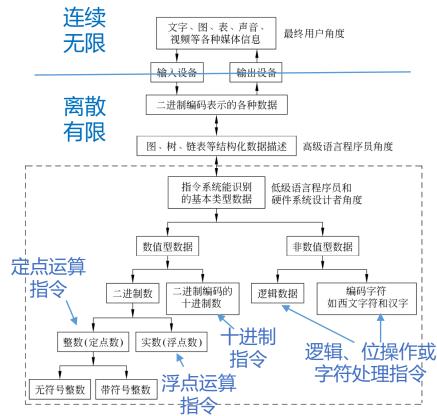


图 2.1 计算机外部信息与内部数据的转换



例: 真值127 = 2<sup>7</sup> - 1, 机器数为0000 0000 0111 1111

# 回顾:整数的二进制数表示



### 整数的二进制数表示

- 无符号整数
- 有符号整数:原码,反码,移码,补码
  - · 编码是为了解决正负号问题
  - 计算机中几乎**不用反码**,运算**普遍使用补码**
  - 二进制补码的运算
  - 二进制-十进制转换



### 原码表示

真值	二进制	真值	二进制
0	0000	-0	1000
1	0001	-1	<b>1</b> 001
2	<b>0</b> 010	-2	<b>1</b> 010
3	<b>0</b> 011	-3	<b>1</b> 011
4	<b>0</b> 100	-4	<b>1</b> 100
5	<b>0</b> 101	-5	<b>1</b> 101
6	<b>0</b> 110	-6	<b>1</b> 110
7	<b>0</b> 111	-7	<b>1</b> 111



#### 优点:

最直接,便于理解

#### 缺点:

- 0的表示不唯一,不利于程序员编程
- 加、减运算方式不统一,尤其当a < b时,实现a b比较困难
- 需要额外对符号位进行处理,不利于硬件设计



### 补码表示

在一个模运算系统中,一个数与它除以"模"后的余数等价。

#### 时钟是一种模12系统



- 例: 图中时针指向的是10点,要将它拨向6点,有两种拨法
  - 1、逆时针拨4格, 10-4=6
  - 2、顺时针拨8格, 10+8=18=6[mod 12]
- ・ 加和减的统一:
  - 一个负数的补码等于模减该负数的绝对值。
  - 对于某一确定的模,某数减去小于模的另一数,总可以加上另一数负数的补码来代替。
  - 一个负数的补码等于将对应正数补码 各位取反、末位加一

#### 8位二进制示例:

 $0111\ 1111 - 0100\ 0000 = 0111\ 1111 + (1\ 0000\ 0000 - 0100\ 0000)$ =  $0111\ 1111 + 1100\ 0000$ 



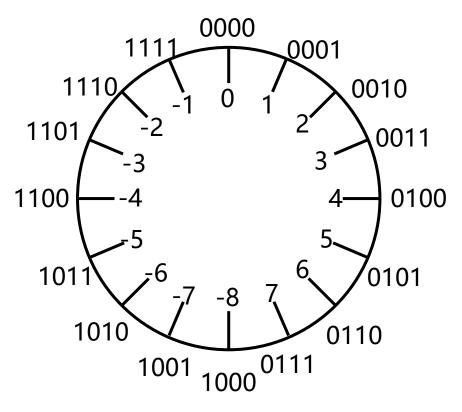
只留余数 = 1 0011 1111 (mod 1 0000 0000)

= 0011 1111

### 补码表示

#### 一个n位运算器,只能保留低n位的运算结果,即模为 $2^n$ 的补码运算

#### 模为24的时钟系统



#### 补码的定义:

$$[X]_c = 2^n + X (-2^n \le X \le 2^n, mod \ 2^n)$$

#### 补码表示:

000...000 ~ 011...111: 表示的值不变

100...000 ~ 111...111: 表示的值由  $2^{k-1} \sim 2^k - 1$ 

变为

$$-2^{k-1} \sim -1$$



## 补码表示法的优势

• 补码表示法 vs. 原码表示法

				补码表	長示法				原码表	長示法	
	9			0000	1001				0000	1001	
+	8		+	0000	1000			+	0000	1000	_
	17			0001	0001	17			0001	0001	17
	9			0000	1001				0000	1001	
+	-8		+	1111	1000		_	+	1000	1000	-
	1	-	1	.0000	0001	1			1001	0001	-17



### 求真值的补码

#### 特殊的真值:

$$[-2^{n-1}]_c = 2^n - 2^{n-1} = 10 \dots 0 (n - 1 \uparrow 0)$$
$$[-1]_c = 2^n - 1 = 11 \dots 1 (n \uparrow 1)$$
$$[+0]_c = [-0]_c = 00 \dots 0 (n \uparrow 0)$$

在32位机器中n为32 int型 32位 short型 16位 char型 8位

#### 一般的例子:

$$123 = 127 - 4 = 0111 \ 11111B - 0000 \ 0100B = 0111 \ 1011B$$
$$-123 = -0111 \ 1011B$$
$$[0111 \ 1011]_c = 2^8 + 0111 \ 1011 = 1 \ 0111 \ 1011 \ (mod \ 2^8) = 0111 \ 1011$$
$$[-0111 \ 1011]_c = 2^8 - 0111 \ 1011 = 1111 \ 1111 - 0111 \ 1011 + 1 = 1000 \ 0101$$

0的补码唯一,为00 ... 0 (n个0) 正数的补码等于它本身 负数的补码为各位取反,末位加1



## 求补码的真值

$$\diamondsuit: [X]_{\mathcal{C}} = x_{n-1}x_{n-2} \dots x_2x_1$$

**则**: 
$$X = -x_{n-1} \times 2^{n-1} + \dots + x_2 \times 2^1 + x_1 \times 2^0$$

#### 真值的范围

$$-2^{n-1} \le X \le 2^{n-1}-1$$

例: 补码1101 0110的真值为

$$-2^7 \times 1 + 2^6 \times 1 + 2^5 \times 0 + 2^4 \times 1 + 2^3 \times 0 + 2^2 \times 1 + 2^1 \times 1 + 2^0 \times 0 = -42$$

#### 简便求法:

符号为0,则为正数,数值部分相同

符号位1,则为负数,数值各位取反,末位加1

**例**: 补码**0101 0110**的真值为

$$+101\ 0110 = 64 + 16 + 4 + 2 = 86$$

**例**:补码**1101 0110**的真值为

$$-010\ 1001 = -(32 + 8 + 1 + 1) = -42$$



### 移码表示

将每一个数值加上一个偏置常数 (excess/bias)

通常当编码位数为n时,bias取 $2^{n-1}$ 或 $2^{n-1}-1$ (如IEEE 754)

例如n=4时, bias=8

真值	二进制	真值	二进制
0	1000	-0	1000
1	1001	-1	0111
2	1010	-2	0110
3	1011	-3	0101
4	1100	-4	0100
5	1101	-5	0011
6	1110	-6	0010
7	1111	-7	0001
		-8	0000

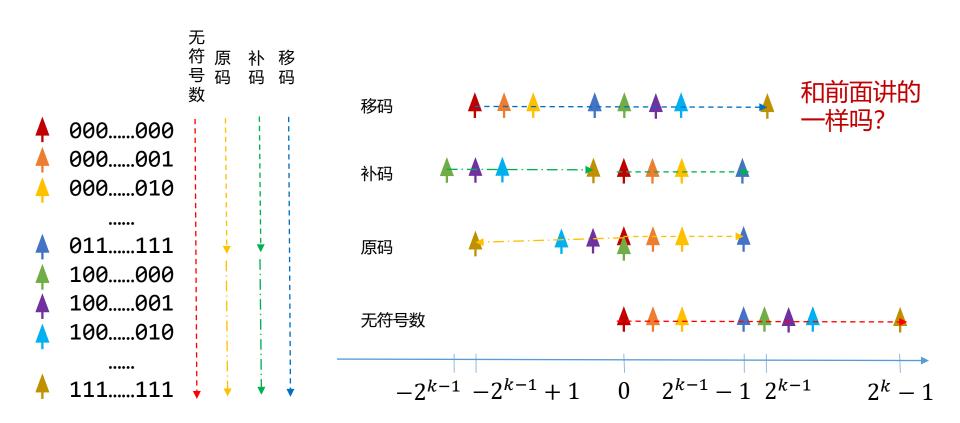


补码: 111<011? 移码: 011<111

此外,全为负数时,移码比原码更容易比较



### 扩展:不同的整数编码



#### 以8位为例,真值的表示范围

• 无符号: 0~255

• 原码: -127~127

• 移码: -127~128

• 补码: -128~127

$$0 \sim 2^{k} - 1$$

$$-2^{k-1} + 1 \sim 2^{k-1} - 1$$

$$-2^{k-1} + 1 \sim 2^{k-1}$$

 $-2^{k-1} \sim 2^{k-1} - 1$ 

#### 移码在IEEE754中

尾数需要右移一位,所以 从-128~127变成了-127~128 实际可用范围是-**126~127** 

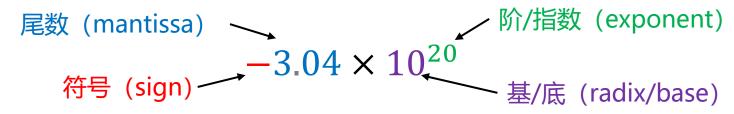


# 回顾: 浮点数的二进制数表示

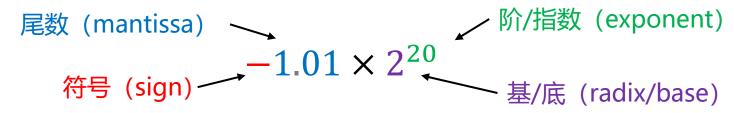


### 浮点数的二进制数表示

#### 十进制数的科学计数法



#### 二进制数的科学计数法



基底不变,对符号、尾数和阶分别编码即可以表示一个浮点数



### 规格化数

• 任何浮点数都能以多种样式来表示

$$0.110 \times 2^5$$
,  $110 \times 2^2$ ,  $0.0110 \times 2^6$ 

• 规格化表示

$$\pm 1.bbb \dots b \times 2^E$$

$$X = (-1)^{\mathbf{S}} \times M \times 2^{E}$$

S	E	M
---	---	---

- 编码方式怎么选?
- 顺序为什么不是SME?
- 位数怎么分配?
- **改进**的空间?



### 规格化数的变化



E使用**移码**: 例如计算  $1.01 \times 2^{-1} + 1.11 \times 2^{3}$ 时,需要将**低阶** (  $2^{-1}$  ) **转为高阶** (  $2^{3}$  ) 那么首先需要**比较-1和3的大小** 

M使用**原码**:对称,无符号时原码的乘法运算简单

其他规格化数的表示形式:  $\pm 0.1bb \dots b \times 2^E$ 

- 对于一定长度的规格化数,表示范围和精度之间存在权衡(总位数不变)
  - 增加阶码(E)位数:扩大表示范围,降低表示精度
  - 增加尾数 (M) 位数: 减少表示范围,提高表示精度,
  - **更大**的底(*B*): 如4, 8, 16, **扩大**表示**范围**, **降低**表示精度

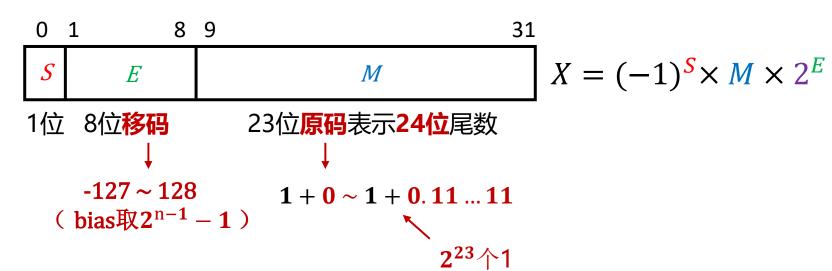
需要一个统一的标准



### 一种规格化表示

• 规格化表示





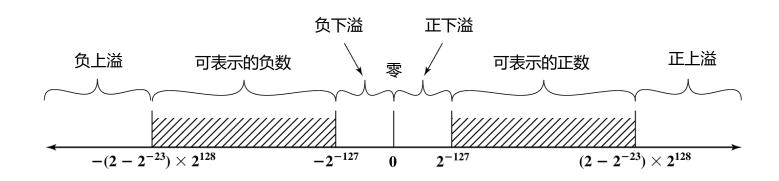
最小正数: *E=0000 0000, M=0.00...00* → **2**<sup>-127</sup>



### 一种规格化数的值的范围

#### • 值的范围

- 介于  $-(2-2^{-23})\times 2^{128}$  和  $-2^{-127}$  之间的负数
- 介于  $2^{-127}$  和  $(2-2^{-23})\times 2^{128}$  之间的正数



原码的表示范围是对称的,所以浮点数值的范围也关于原点对称





Larger Photo

William M. Kahan
Professor Emeritus

Research Areas

Computer Architecture & Engineering (ARC)

Scientific Computing (SCI)

Computer architecture; Scientific computing; Numerical analysis

20世纪70年代,IEEE成立委员会着手制 定浮点数标准。

20世纪80年代,Intel邀请Kahan教授设计8087处理器的浮点运算单元。

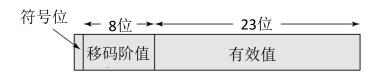
IEEE邀请Kahan基于8087中的浮点标准 起草一份通用标准。

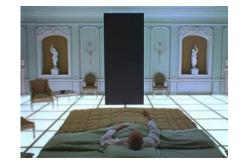
1985年提出浮点数标准IEEE 754。

1989年Kahan教授因此获得ACM A.M Turing Award



#### · 定义32位的单精度和64位的双精度两种格式







#### ・定义两种拓展格式

- 扩展单精度浮点格式 (≥43 位,不常用)。
- 扩展双精度浮点格式 (≥79 位,一般情况下, Intel x86 结构的计算机采用的是 80 位,而 SPARC 结构的计算机采用的是 128 位)。



#### 单精度浮点数



- S: 1表示负, 0表示正
- E: 全0和全1表示特殊值, 范围是 0000 0001 (-126) ~ 1111 1110 (127)
- M: 最高位总是1, 所以隐含表示

阶码的范围为什么是-126~127? 为什么不是-127~128?

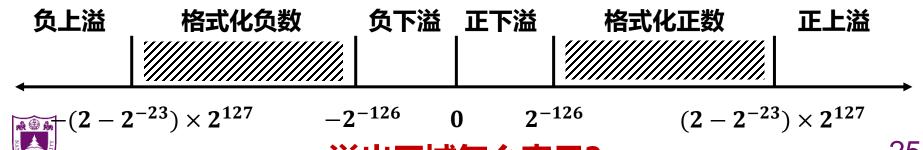


#### IEEE754 格式化浮点数表示范围

格式	最小正数	最大正数	最小负数	最大负数
单精度	$E = 1$ $M = 0$ $1.0 \times 2^{-126}$	$E = 254$ $M = 1 - 2^{-23}$ $(2 - 2^{-23}) \times 2^{127}$	$E=254$ $M=1-2^{-23}$ $-(2-2^{-23}) \times 2^{127}$	$E = 1  M = 0  -1.0 \times 2^{-126}$
双精度	$E=1$ $M=0$ $1.0 \times 2^{-1022}$	$E = 2046$ $M = 1 - 2^{-52}$ $(2 - 2^{-52}) \times 2^{1023}$	$E=2046$ $M=1-2^{-52}$ $-(2-2^{-52})\times 2^{1023}$	$E=1$ $M=0$ $-1.0 \times 2^{-1022}$

注:均为真值

#### 原码的表示范围是对称的,所以浮点数值的范围也关于原点对称



溢出区域怎么表示?

阶码的值	尾数的值	 表示
0 (全0)	0	+/- 0
0 (全0)	<b>           </b>	非规格化数
1~254	任意	规格化数
255 (全1)	0	+/- ∞
255 (全1)	≢0	NaN

#### 全0和全1

- 用于表示格式化数以外的情况
- 负上溢和正上溢中只能表示无穷



### • 格式参数

<del></del> ₩b	格式						
<b>参数</b>	单精度	单精度拓展	双精度	双精度拓展			
字宽(位数)	32	≥43	64	≥79			
阶值位宽(位数)	8	≥11	11	≥15			
阶值偏移量	127	未指定	1023	未指定			
最大阶值	127	≥1023	1023	≥16383			
最小阶值	-126	≤-1022	-1022	≤-16382			
数的范围(底为10)	$10^{-38}, 10^{+38}$	未指定	$10^{-308}, 10^{+308}$	未指定			
有效值位宽(位数)	23	≥31	52	≥63			
阶值的数目	254	未指定	2046	未指定			
小数的数目	$2^{23}$	未指定	2 <sup>52</sup>	未指定			
值的数目	$1.98 \times 2^{31}$	未指定	$1.99 \times 2^{63}$	未指定			



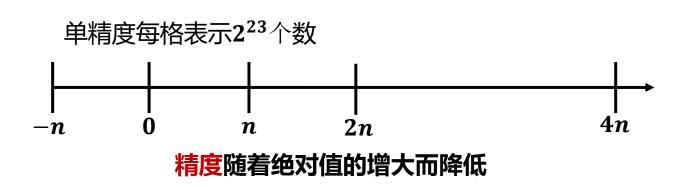
小数第一位: 0 用法:表示未初始化的值,用于捕获异常 小数第一位: 1

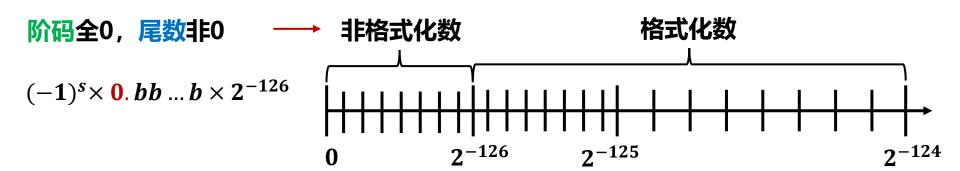
用法:表示未定义的算术结果,如除数等于0

		单精度	单精度(32位)        双精度(64位)					
	符号	移码阶值	小数	值	符号	移码阶值	小数	值
正零	0	0	0	0	0	0	0	0
负零	1	0	0	-0	1	0	0	-0
正无穷大	0	255 (all 1s)	0	<b>%</b>	0	2047 (all 1s)	0	$\infty$
负无穷大	1	255 (all 1s)	0	$-\infty$	1	2047 (all 1s)	0	$-\infty$
静默式非数	0 or 1	255 (all 1s)	≠0	NaN	0 or 1	2047 (all 1s)	≠0	NaN
通知式非数	0 or 1	255 (all 1s)	≠0	NaN	0 or 1	2047 (all 1s)	≠0	NaN
正的规格 化非零数	0	0 < e < 255	f	2 <sup>e-127</sup> (1.f)	0	0 < e < 2047	f	2 <sup>e-1023</sup> (1.f)
负的规格 化非零数	1	0 < e < 255	f	$-2^{e-127}(1.f)$	1	0 < e < 2047	f	$-2^{e-1023}(1.f)$
正的非规 格化数	0	0	f ≠ 0	2 <sup>e-126</sup> (0.f)	0	0	f ≠ 0	$2^{e-1022}(0.f)$
五 5 5 5 6 6 6 7 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8	1	0	f ≠ 0	$-2^{e-126}(0.f)$	1	0	f ≠ 0	$-2^{e-1022}(0.f)$



精度不够怎么办? 舍入原则







• 例子

```
0.5 = 0.100...0B = (1.00..0)2\times2^{-1}
0.1111110 000...00 (23)
-0.4375 = -0.01110...0B = - (1.110...0)2\times2^{-2}
1.01111101 110...00 (21)
```



### 二进制编码的十进制数表示

- 浮点运算的问题
  - 精度限制
  - 转换成本高
- 应用需要
  - 长数字串的计算: 会计, ......
- 解决方法
  - 用4位二进制编码十进制 (BCD) 表示0, 1, ..., 9, 直接计算



### 二进制编码的十进制数表示

- 自然BCD码 (NBCD, 8421 码)
  - 0 ~ 9: 0000 ~ 1001
  - 符号: 使用四个最高有效位
    - 正: 1100 / 0
    - 负: 1101 / 1
  - 例子
    - +2039: **1100** 0010 0000 0011 1001 / **0** 0010 0000 0011 1001
    - -1265: 1101 0001 0010 0110 0101 / 1 0001 0010 0110 0101
- ·其他BCD码
  - 2421, 5211, 4311, ...



### 非数值数据的编码表示

#### ・逻辑值

- 逻辑数据和数值数据在形式上**没有差异**
- 通过指令的操作码类型来识别运算类型,如逻辑运算指令,算术运算指令。

#### ・西文字符

- 有**多种**不同的**字符集**
- 最广泛使用的是ASCII码
  - ・7位或8位二进制表示

#### ・汉字字符

- · 一个字就是一个方块图形
- 如GB2312-80字符集
- 超过6万个字(至少16位)

音频等)

			表 2.6	ASCII 码	表			
$b_3b_2b_1b_0$ $b_6b_5b_4$	000	001	010	011	100	101	110	111
0000	NUL	DLE	SP	0	@	P	,	p
0001	SOH	DC1	!	1	A	Q	a	q
0010	STX	DC2	-	2	В	R	ь	r
0011	ETX	DC3	#	3	С	s	c	s
0100	EOT	DC4	\$	4	D	Т	d	t
0101	ENQ	NAK	%	5	Е	U	e	u
0110	ACK	SYN	8:-	6	F	v	f	v
0111	BEL	ETB		7	G	w	g	w
1000	BS	CAN	(	8	Н	X	h	x
1001	НТ	EM	)	9	I	Y	i	у
1010	LF	SUB	*	:	J	Z	j	z
1011	VT	ESC	+	;	K	[	k	{
1100	FF	FS	,	<	L	\	1	1
1101	CR	GS	_	-	М	]	m	}
1110	SO	RS		>	N	•	n	~
1111	SI	US	/	?	0	_	О	DEL

· 同样用0和1表示,**数据结构**各异

### 总结

- 信息的二进制编码
- 整数的二进制表示
  - 补码表示的优势,表示方法,真值计算
  - 不同的整数二进制表示
- 浮点数的二进制表示
  - 浮点数表示方法, 规格化数, 非规格化数, IEEE 754标准
- 二进制编码的十进制数表示
  - NBCD码表示方法
- 非数值数据的编码表示
  - 逻辑值, 西文字符, 汉字字符, 多媒体信息



# 谢谢

bohanliu@nju.edu.cn

